

Diego Alejandro Quiroz Ruiz

06/01/2026

2º ASIR

Tarea. Crear un modelo de LLM



Índice

1. Preparación del entorno y herramientas.....	3
2. Definición del conocimiento (Dataset).....	3
3. Configuración del entrenamiento (Fine-Tuning).....	4
4. Cuantización: Del entrenamiento al uso local.....	5
5. Puesta en marcha y verificación.....	5

1. Preparación del entorno y herramientas

En primer lugar, lo primero que se hizo fue limpiar el área de trabajo eliminando versiones anteriores para evitar conflictos en el desarrollo, tras eso simplemente crear un entorno nuevo con Python 3.11 y activarlo para empezar la instalación de dependencias.

Realicé la instalación de Axolotl para el entrenamiento con las librerías que permiten al modelo aprender de los datos proporcionados de forma adecuada.

```
((venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % rm -rf venv
((venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % python3.11 -m venv venv
((venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % source venv/bin/activate
((venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % pip install "axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl"
Collecting axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl
  Cloning https://github.com/OpenAccess-AI-Collective/axolotl to /private/var/folders/x7/5vw0c3rx46j0b hmp88zdy3zm000gn/T/pip-install-0o_ika1v/axolotl_c6c119a320f94583bc3134b9ecc3fdd0
  Running command git clone --filter=blob:none --quiet https://github.com/OpenAccess-AI-Collective/axolotl /private/var/folders/x7/5vw0c3rx46j0b hmp88zdy3zm000gn/T/pip-install-0o_ika1v/axolotl_c6c119a320f94583bc3134b9ecc3fdd0
  Resolved https://github.com/OpenAccess-AI-Collective/axolotl to commit 236dad3bb7954e5dc8dcca5b4d067a7e6e39fb7e
  Installing build dependencies ... done
  Getting requirements to build wheel ... done
  Preparing metadata (pyproject.toml) ... done
Collecting packaging==26.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached packaging-26.0-py3-none-any.whl.metadata (3.3 kB)
Collecting huggingface_hub>=1.1.7 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached huggingface_hub-1.4.0-py3-none-any.whl.metadata (13 kB)
Collecting peft>=0.18.1 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached peft-0.18.1-py3-none-any.whl.metadata (14 kB)
Collecting tokenizers>=0.22.1 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached tokenizers-0.22.2-cp39-abi3-macosx_11_0_arm64.whl.metadata (7.3 kB)
Collecting transformers=5.0.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached transformers-5.0.0-py3-none-any.whl.metadata (37 kB)
Collecting accelerate==1.12.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached accelerate-1.12.0-py3-none-any.whl.metadata (19 kB)
Collecting datasets==4.5.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached datasets-4.5.0-py3-none-any.whl.metadata (19 kB)
Collecting trl==0.27.1 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached trl-0.27.1-py3-none-any.whl.metadata (11 kB)
Collecting hf_xet==1.2.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached hf_xet-1.2.0-cp37-abi3-macosx_11_0_arm64.whl.metadata (4.9 kB)
Collecting kernels==0.11.5 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached kernels-0.11.5-py3-none-any.whl.metadata (3.3 kB)
Collecting trackio>=0.13.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached trackio-0.15.0-py3-none-any.whl.metadata (9.9 kB)
Collecting typing_extensions>=4.15.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached typing_extensions-4.15.0-py3-none-any.whl.metadata (3.3 kB)
Collecting optimum==1.16.2 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached optimum-1.16.2-py3-none-any.whl.metadata (17 kB)
Collecting hf_transfer (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Using cached hf_transfer-0.1.9-cp38-abi3-macosx_11_0_arm64.whl.metadata (1.7 kB)
Collecting sentencepiece (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
  Downloading sentencepiece-0.2.1-cp311-cp311-macosx_11_0_arm64.whl.metadata (10 kB)
Collecting gradio<7.0,>=6.2.0 (from axolotl @ git+https://github.com/OpenAccess-AI-Collective/axolotl)
```

2. Definición del conocimiento (Dataset)

Para que el modelo se volviese experto en cocina, creé el archivo llamado recetas.jsonl donde se definen ejemplos claros de instrucciones de cocina. Por ejemplo, puse que si un usuario tiene patatas y huevos, la respuesta debe ser una receta de tortilla de patatas.

```
UW PICO 5.09 File: recetas.jsonl Modified
{"instruction": "Tengo pechugas de pollo, limón y ajo.", "output": "¡Claro! Puedes preparar unas 'Pec$"}
{"instruction": "Ingredientes: patatas, huevos, cebolla.", "output": "Con eso, la receta estrella es $"}
$ un plato, añade hojas de albahaca fresca y aliña con sal, pimienta y aceite de oliva."}]
```

3. Configuración del entrenamiento (Fine-Tuning)

Aquí es donde ajusta el archivo `config_chef.yml`, donde se eligió como motor el modelo Phi-3-mini. Sin embargo, para no saturar el Mac Mini se hicieron ciertos ajustes:

- LoRA: En lugar de entrenar todo el modelo, se utilizaron adaptadores LoRA porque son más ligeros.
- Optimización de RAM: Reduciendo la longitud de secuencia a 256 tokens para que la RAM no sufriera durante el proceso.
- Precisión: Configuración del entrenamiento para que fuera estable, evitando así formatos que el Mac no maneja tan bien localmente.

```
UW PICO 5.09 File: config_chef.yml Modified
base_model: microsoft/Phi-3-mini-4k-instruct
model_type: PhiForCausalLM
tokenizer_type: AutoTokenizer

# Configuración para bajo consumo (Mac)
load_in_4bit: false # Mac maneja mejor FP16 o BF16 que 4bit en entrenamiento local
load_in_8bit: false
bf16: false
fp16: false # El Mac mini usará float32 por defecto para mayor estabilidad
tf32: false
flash_attention: false
local_rank: 0
adapter: lora

datasets:
  - path: recetas.jsonl
    type: alpaca

dataset_prepared_path: last_run_prepared
val_set_size: 0.05
sequence_len: 256 # Bajamos esto de 1024 a 256 para que tu RAM no sufra
sample_packing: true

lora_r: 8 # Reducimos la complejidad del adaptador
lora_alpha: 16
lora_dropout: 0.05
lora_target_modules:
  - qkv_proj

num_epochs: 2 # Menos vueltas para terminar rápido
micro_batch_size: 1
gradient_accumulation_steps: 1
gradient_checkpointing: true
learning_rate: 0.0002
optimizer: adamw_torch
```

4. Cuantización: Del entrenamiento al uso local

Ahora que el modelo "aprendió" las recetas, toca convertirlo a un formato que el Mac Mini pueda ejecutar de forma fluida de la siguiente forma:

- Clonación y compilación de llama.cpp.
- Descarga del modelo base original desde Hugging Face con Git LFS.
- Ejecución del script `convert_hf_to_gguf.py` para transformar el modelo al formato GGUF y cuantización `q8_0`. Lo que hace esto es que permite reducir el peso del modelo pero manteniendo la alta calidad.

```
(venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % ls
config_chef.yml  recetas.jsonl  venv
(venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % git clone https://github.com/ggerganov/llama.cpp
Clonando en 'llama.cpp'...
remote: Enumerating objects: 78196, done.
remote: Counting objects: 100% (89/89), done.
remote: Compressing objects: 100% (65/65), done.
remote: Total 78196 (delta 53), reused 24 (delta 24), pack-reused 78107 (from 3)
Recibiendo objetos: 100% (78196/78196), 285.39 MiB | 44.84 MiB/s, listo.
Resolviendo deltas: 100% (56583/56583), listo.
(venv) aulaateca26@Mac-mini-de-aulaateca26 mi-chef-bot % cd llama.cpp
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % make
Makefile:6: *** Build system changed:
The Makefile build has been replaced by CMake.

For build instructions see:
https://github.com/ggml-org/llama.cpp/blob/master/docs/build.md

. Stop.
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp %
```

```
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % pip install -r requirements.txt
Looking in indexes: https://pypi.org/simple, https://download.pytorch.org/whl/cpu, https://download.pytorch.org/whl/nightly, https://download.pytorch.org/whl/cpu, https://download.pytorch.org/whl/nightly, https://download.pytorch.org/whl/cpu, https://download.pytorch.org/whl/nightly
Ignoring torch: markers 'platform_machine == "s390x"' don't match your environment
Ignoring torch: markers 'platform_machine == "s390x"' don't match your environment
Collecting numpy==1.26.4 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_legacy_llama.txt (line 1))
Using cached numpy-1.26.4-cp311-cp311-macosx_11_0_arm64.whl.metadata (114 kB)
Requirement already satisfied: sentencepiece==0.2.0 in /Users/aulaateca26/mi-chef-bot/venv/lib/python3.11/site-packages (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_legacy_llama.txt (line 2)) (0.2.1)
Collecting transformers<5.0.0,>=4.57.1 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_legacy_llama.txt (line 4))
Using cached transformers-4.57.6-py3-none-any.whl.metadata (43 kB)
Collecting gguf>=0.1.0 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_legacy_llama.txt (line 6))
Using cached https://download.pytorch.org/whl/nightly/gguf-0.17.1-py3-none-any.whl.metadata (4.3 kB)
Collecting protobuf<5.0.0,>=4.21.0 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_legacy_llama.txt (line 7))
Using cached protobuf-4.25.8-cp37-abi3-macosx_10_9_universal2.whl.metadata (541 bytes)
Collecting torch==2.6.0 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-convert_hf_to_gguf.txt (line 5))
Using cached https://download.pytorch.org/whl/cpu/torch-2.6.0-cp311-none-macosx_11_0_arm64.whl.metadata (28 kB)
Collecting aiohttp==3.9.3 (from -r /Users/aulaateca26/mi-chef-bot/llama.cpp/requirements/requirements-tool_bench.txt (line 1))
Using cached https://download.pytorch.org/whl/nightly/aiohttp-3.9.5-cp311-cp311-macosx_11_0_arm64.whl (390 kB)
```

```
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % git lfs install
Updated Git hooks.
Git LFS initialized.
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % git clone https://huggingface.co/microsoft/Phi-3-mini-4k-instruct
Clonando en 'Phi-3-mini-4k-instruct'...
remote: Enumerating objects: 111, done.
remote: Counting objects: 100% (6/6), done.
remote: Compressing objects: 100% (6/6), done.
remote: Total 111 (delta 1), reused 0 (delta 0), pack-reused 105 (from 1)
Recibiendo objetos: 100% (111/111), 1.03 MiB | 3.99 MiB/s, listo.
Resolviendo deltas: 100% (52/52), listo.
Filtrando contenido: 100% (3/3), 3.11 GiB | 24.01 MiB/s, listo.
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp %
```

```
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % ls -ld ../*/
../llama.cpp/
../Phi-3-mini-4k-instruct/
../venv/
(venv) aulaateca26@Mac-mini-de-aulaateca26 llama.cpp % python convert_hf_to_gguf.py ../Phi-3-mini-4k-i
nstruct --outfile ../chef-bot-v1.gguf --outtype q8_0
INFO:hf-to-gguf:Loading model: Phi-3-mini-4k-instruct
INFO:hf-to-gguf:Model architecture: Phi3ForCausalLM
INFO:hf-to-gguf:gguf: loading model weight map from 'model.safetensors.index.json'
INFO:hf-to-gguf:gguf: indexing model part 'model-00001-of-00002.safetensors'
INFO:hf-to-gguf:gguf: indexing model part 'model-00002-of-00002.safetensors'
INFO:gguf:gguf_writer:gguf: This GGUF file is for Little Endian only
INFO:hf-to-gguf:Exporting model...
INFO:hf-to-gguf:token_embd.weight, torch.bfloat16 --> Q8_0, shape = {3072, 32064}
INFO:hf-to-gguf:blk.0.attn_norm.weight, torch.bfloat16 --> F32, shape = {3072}
INFO:hf-to-gguf:blk.0.ffn_down.weight, torch.bfloat16 --> Q8_0, shape = {8192, 3072}
INFO:hf-to-gguf:blk.0.ffn_up.weight, torch.bfloat16 --> Q8_0, shape = {3072, 16384}
INFO:hf-to-gguf:blk.0.ffn_norm.weight, torch.bfloat16 --> F32, shape = {3072}
INFO:hf-to-gguf:blk.0.attn_output.weight, torch.bfloat16 --> Q8_0, shape = {3072, 3072}
INFO:hf-to-gguf:blk.0.attn_qkv.weight, torch.bfloat16 --> Q8_0, shape = {3072, 9216}
INFO:hf-to-gguf:blk.1.attn_norm.weight, torch.bfloat16 --> F32, shape = {3072}
INFO:hf-to-gguf:blk.1.ffn_down.weight, torch.bfloat16 --> Q8_0, shape = {8192, 3072}
INFO:hf-to-gguf:blk.1.ffn_up.weight, torch.bfloat16 --> Q8_0, shape = {3072, 16384}
INFO:hf-to-gguf:blk.1.ffn_norm.weight, torch.bfloat16 --> F32, shape = {3072}
INFO:hf-to-gguf:blk.1.attn_output.weight, torch.bfloat16 --> Q8_0, shape = {3072, 3072}
INFO:hf-to-gguf:blk.1.attn_qkv.weight, torch.bfloat16 --> Q8_0, shape = {3072, 9216}
INFO:hf-to-gguf:blk.10.attn_norm.weight, torch.bfloat16 --> F32, shape = {3072}
```

5. Puesta en marcha y verificación

Finalmente: se carga el archivo chef-bot-v1.gguf en la interfaz del chat, se configura el uso de la GPU y se configura el uso de la memoria.

En la prueba final, le pregunté qué hacer con garbanzos, espinacas y curry. Con este resultado:

Chef Bot v1

Estimated Memory Usage Beta

GPU 5.72 GB Total 5.72 GB

API Identifier

Optional: provide an identifier for this model. This will be used in API requests. Leave blank to use the default identifier.

practica

Auto Unload if Idle (TTL) ☐

If set, the model will be automatically unloaded after being idle for the specified amount of time.

Context Length 4096

Model supports up to 4096 tokens

GPU Offload 32 / 32

CPU Thread Pool Size 7

Evaluation Batch Size 512

RoPE Frequency Base ☐ Auto

RoPE Frequency Scale ☐ Auto

Offload KV Cache to GPU Memory ☒

Keep Model in Memory ☒

Try mmap() ☒

Seed Random Seed

Flash Attention ☒


K Cache Quantization Type ☐ Experimental

V Cache Quantization Type ☐ Experimental

☐ Remember settings for chef-bot-v1

Cancel Load Model

☒ Show advanced settings



practica

Unnamed Chat

Hola Chef, tengo solo un bote de garbanzos, espinacas y un poco de curry. ¿Qué puedo hacer?

practica

¡Claro que sí! Puedes preparar una deliciosa sopa o estofado con los ingredientes que tienes a mano. Aquí te dejo una receta simple para empezar:

Curry Garbanzos y Espinacas (Sopa)

Ingredientes:

- 1 bote de garbanzos, bien cocidos o frescos si puedes precalentarlos al vapor.
- Aproximadamente 2 tazas de espinacas frescas picadas. Si no las has comprado ya cortadas, hazlo antes del uso para ahorrar tiempo y energía en el horno microondas o una cacerola con agua hirviendo.
- Saborizante curry que prefieras (podrías elegir un curry rojo típico de la India, como el Garam Masala). Aproximadamente 1/2 cucharadita para darle sabor al caldo y más si lo deseas.
- Sal al gusto
- Pimienta negra recién molida (opcional)
- Cilantro fresco picado (para decorar, opcional pero recomendable)