

Diego Alejandro Quiroz Ruiz

15/01/2026

2º ASIR

Tarea. Cuantización



Índice


1. Objetivo principal.

El objetivo principal fue comparar el rendimiento, el uso de memoria RAM y el tamaño en disco del modelo de lenguaje “Phi-3 Mini” en su versión original contra una versión cuantizada. La comprobación se hizo mediante LM_Studio.

2. Comparativa de tamaño.

- **Modelo No Cuantizado (Phi-3 Mini F16):** Ocupa 7.12 GB.
- **Modelo Cuantizado (Phi-3 Mini Q4):** El tamaño se redujo a 2.23 GB.

Es decir, se logró una reducción de espacio del 68% (aproximadamente).



Your Models		Recency ↓	Size	Downloaded
Phi 3 Mini	F16	lmstudio-community	3B	ph13 GGUF 7.12 GB >
Phi 3 Mini	Q4	lmstudio-community	3B	ph13 GGUF 2.23 GB >

3. Carga en la memoria RAM.

- **Sin cuantizar:** El consumo de memoria del sistema sube a 8.74 GB.



- **Cuantizado:** El consumo baja a 3.85 GB.



4. Pruebas de Velocidad y Respuesta.

El modelo cuantizado es mucho más rápido y responde en casi la mitad de tiempo al primer token.

Métrica	Modelo No Cuantizado (F16)	Modelo Cuantizado (Q4)
Velocidad	14.58 tok/sec	41.4 tok/sec
Tiempo primer token	0.23	0.13
Respuesta	"¡Buenos días! ¿Cómo puedo asistirte...?"	"¡Hola! ¿En qué puedo ayudarte hoy?"

5. Conclusión.

La cuantización Q4 permite que se ejecuten modelos de forma mucho más fluida, aunque se reduzca la precisión, sigue respondiendo de forma lógica y profesional, liberando casi 5 GB de RAM para otras tareas y mejorando mucho la velocidad de generación de texto.