

Diego Alejandro Quiroz Ruiz

15/01/2026

2º ASIR

---

## Tarea. Cuantización



---

# Índice

|                                          |   |
|------------------------------------------|---|
| 1. Objetivo principal.....               | 3 |
| 2. Comparativa de tamaño.....            | 3 |
| 3. Carga en la memoria RAM.....          | 3 |
| 4. Pruebas de Velocidad y Respuesta..... | 4 |
| 5. Conclusión.....                       | 4 |

---

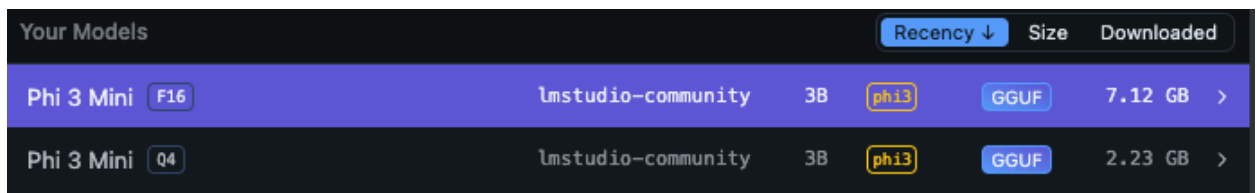
## 1. Objetivo principal.

El objetivo principal fue comparar el rendimiento, el uso de memoria RAM y el tamaño en disco del modelo de lenguaje “Phi-3 Mini” en su versión original contra una versión cuantizada. La comprobación se hizo mediante LM\_Studio.

## 2. Comparativa de tamaño.

- **Modelo No Cuantizado (Phi-3 Mini F16):** Ocupa 7.12 GB.
- **Modelo Cuantizado (Phi-3 Mini Q4):** El tamaño se redujo a 2.23 GB.

Es decir, se logró una reducción de espacio del 68% (aproximadamente).



| Your Models |     | Recency ↓          | Size | Downloaded          |
|-------------|-----|--------------------|------|---------------------|
| Phi 3 Mini  | F16 | lmstudio-community | 3B   | ph13 GGUF 7.12 GB > |
| Phi 3 Mini  | Q4  | lmstudio-community | 3B   | ph13 GGUF 2.23 GB > |

## 3. Carga en la memoria RAM.

- **Sin cuantizar:** El consumo de memoria del sistema sube a 8.74 GB.



- **Cuantizado:** El consumo baja a 3.85 GB.



---

## 4. Pruebas de Velocidad y Respuesta.

El modelo cuantizado es mucho más rápido y responde en casi la mitad de tiempo al primer token.

| Métrica                    | Modelo No Cuantizado (F16)                | Modelo Cuantizado (Q4)               |
|----------------------------|-------------------------------------------|--------------------------------------|
| <b>Velocidad</b>           | 14.58 tok/sec                             | 41.4 tok/sec                         |
| <b>Tiempo primer token</b> | 0.23                                      | 0.13                                 |
| <b>Respuesta</b>           | "¡Buenos días! ¿Cómo puedo asistirte...?" | "¡Hola! ¿En qué puedo ayudarte hoy?" |

## 5. Conclusión.

La cuantización Q4 permite que se ejecuten modelos de forma mucho más fluida, aunque se reduzca la precisión, sigue respondiendo de forma lógica y profesional, liberando casi 5 GB de RAM para otras tareas y mejorando mucho la velocidad de generación de texto.